

# Modelagem Bayesiana e Aplicações

Márcia D'Elia Branco

Universidade de São Paulo  
Instituto de Matemática e Estatística  
<http://www.ime.usp.br/~mbranco>

## Modelos Hierárquicos 2

# Modelo Hierárquico Normal

Primeiro nível

$$\bar{y}_j \mid \theta_j \sim N(\theta_j, \sigma_j^2)$$

$$\text{com } \bar{y}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} y_{ij} \text{ e } \sigma_j^2 = \frac{\sigma}{n_j}.$$

Segundo nível

$$\theta_j \mid \mu, \tau^2 \sim N(\mu, \tau^2)$$

Obtivemos a seguinte distribuição a posteriori condicional aos hiperparâmetros:

$$h(\theta \mid \mu, \tau, y) = \prod_{j=1}^J \phi(\theta_j; A_j, V_j)$$

# Modelo Hierárquico Normal

em que  $\phi()$  representa a fdp da normal e

$$V_j = \left[ \frac{1}{\sigma_j^2} + \frac{1}{\tau^2} \right]^{-1} \quad A_j = V_j \left[ \frac{\bar{y}_j}{\sigma_j^2} + \frac{\mu}{\tau^2} \right]$$

Note que o valor esperado de  $\theta_j$  é uma combinação linear entre a média do grupo  $j$  e a média global  $\mu$ .

Reescrevemos

$$V_j = \tau^2 T_j \quad \text{e} \quad A_j = (1 - T_j)\bar{y}_j + T_j\mu,$$

com  $T_j = \frac{\sigma_j^2}{\sigma_j^2 + \tau^2}.$

Escolha das (hiper)prioris.

## 1. Não informativas impróprias:

Se  $h(\mu) \propto 1$  então a distribuição a posteriori condicional a  $\tau$  é

$$\mu \mid \tau, y \sim N(\hat{\mu}, V_{\mu})$$

com

$$V_{\mu} = \left[ \sum_{j=1}^J \frac{1}{\sigma_j^2 + \tau^2} \right]^{-1} \quad \hat{\mu} = V_{\mu} \sum_{j=1}^J \frac{\bar{y}_j}{\sigma_j^2 + \tau^2}$$

Usualmente considera-se uma uniforme na transformação  $\log(\tau)$ . Mas neste problema não é adequada pois a posteriori resulta imprópria.

Alternativamente, considera-se uma priori uniforme imprópria em  $\tau$ . (Exercício: mostrar que a posteriori é própria!).

**A distribuição a posteriori para  $\tau$ .**

Note que

$$h(\tau | y) = \frac{h(\mu, \tau | y)}{h(\mu | \tau, y)}$$

Lembramos que obtivemos na última aula

$$f(y \mid \mu, \tau) = \prod_{j=1}^J \phi(\bar{y}_j; \mu, \sigma_j^2 + \tau^2)$$

Como  $h(\mu, \tau) \propto 1$ , resulta

$$h(\tau \mid y) \propto \frac{\prod_{j=1}^J \phi(\bar{y}_j; \mu, \sigma_j^2 + \tau^2)}{\phi(\mu; \hat{\mu}, V_{\mu})}$$

Como essa distribuição é unidimensional não é difícil simular.  
Podemos usar o algoritmo dada na função *sim.x* () no apêndice B do livro Turkman et al..

## Esquema de simulação da distribuição a posteriori

- 1 Simular  $\tau^t$  da marginal  $h(\tau \mid y)$ .
- 2 Simular  $\mu^t$  da  $N(\hat{\mu}^t, V_\mu^t)$
- 3 Simular  $\theta_j^t$  da  $N(A_j^t, V_j^t)$  independente para  $j = 1, \dots, J$ .
- 4 Fazer  $t = 1, 2, \dots, M$

Não há necessidade de controlar a convergência, pois é um esquema de simulação direta que não envolve Cadeias de Markov.

## 2. Prioris Vagas (pouco informativas e próprias)

$$\mu \sim N(0, 10^k) \quad , \quad \gamma = \frac{1}{\tau^2} \sim \text{Gama}(\epsilon, \epsilon)$$

Escolhendo  $k$  grande e  $\epsilon$  pequeno.

$$E[\gamma] = 1 \quad \text{Var}[\gamma] = \frac{1}{\epsilon}$$

O modelo pode ser escrito no OpenBUGS ou JAGS e a inferência obtida via MCMC.



## 3. Algumas alternativas de prioris para $\tau$

3.1. *Half-Cauchy* :  $\tau = \frac{d_1}{\sqrt{d_2}}$  com

$$d_1 \sim N(0, D)I_{(0, \infty)} \quad \text{e} \quad d_2 \sim X_1^2.$$

**Exercício:** Mostrar que  $\tau$  tem distribuição de Cauchy restrita aos valores positivos.

3.2 . Uniforme nos pesos (*shrinkage*) .

Considera uma Uniforme no intervalo  $(0, 1)$  para os pesos

$$T = \frac{\sigma^2}{\sigma^2 + \tau^2}.$$

Vamos obter a distribuição de  $\tau^2$ .

A transformação inversa é dada por  $\tau^2 = \frac{\sigma^2}{T} - \sigma^2$ .

Então





$$P(\tau^2 \leq y) = P\left(\frac{\sigma^2}{T} - \sigma^2 \leq y\right) = P\left(T \geq \frac{\sigma^2}{\sigma^2 + y}\right) =$$

$$1 - \frac{\sigma^2}{\sigma^2 + y} = \frac{y}{\sigma^2 + y}.$$

Derivando obtemos a densidade que resulta em

$$h(\tau^2 \mid \sigma^2) = \frac{\sigma^2}{(\sigma^2 + \tau^2)^2}, \tau^2 > 0.$$

# Prioris para $\tau^2$



## 3.3. Proposta de Gustafson et al. (2006).

$$h(\tau \mid \sigma^2) = \frac{a}{\sigma^2(1 + \tau^2/\sigma^2)^{a+1}}$$

- Para grandes valores de  $a$  evita estimativas muito altas para  $\tau$ .  
Priori conservativa.
- Para  $a = 1$  ela é igual a Uniforme nos pesos.

**Exemplo:** Livro Gelman et al. (2014), pag.119.

Interesse: avaliar o efeito de um programa de treinamento para melhorar a performance em um determinado teste.

Foram analisadas  $J = 8$  escolas. Para cada uma delas foi obtida uma medida resumo das diferenças de desempenho dos alunos "treinados" e "não treinados", denotada por  $y_j$ ,  $j = 1, \dots, 8$ .

Além disso, as variâncias amostrais de cada grupo são consideradas muito próximas das populacionais, devido ao fato dos tamanhos de amostras serem grandes. Os dados são apresentados na tabela a seguir.

# Modelo Hierárquico Normal

Escola	$y_j$	$\sigma_j$
A	28	15
B	8	10
C	-3	16
D	7	11
E	-1	9
F	1	11
G	18	10
H	12	18

# Modelo Hierárquico Normal

- Olhando para as estimativas pontuais pode parecer que algumas escolas tiveram um desempenho destacado em relação às outras.
- No entanto, ao analisarmos os desvios padrões (valores muito altos) notamos que não há diferença significativa entre elas. Os intervalos de credibilidades para cada um dos  $\theta_j$  se interseccionam.
- Podemos então pensar que todas escolas provêm de uma mesma população e considerar um único  $\theta$ . Neste caso, a estimativa pontual é 7.7 com um desvio padrão de 4.1.
- As conclusões obtidas com os dois modelos são bastante distintas. Por exemplo, considerando a análise individual temos que  $P(\theta_1 > 28 | y) = 0.5$ . Já na análise conjunta,  $P(\theta_1 > 28 | y) \approx 0$ .

# Modelo Hierárquico Normal

Foi ajustado o modelo com hiperpriori uniforme em  $(\mu, \tau)$  .  
Na tabela a seguir temos as estimativas dos  $\theta_j$  para uma amostra simulada de tamanho  $M = 200$ .

Escola	2.5 %	25 %	mediana	75 %	97.5 %
A	-2	7	10	16	31
B	-5	3	8	12	23
C	- 11	2	7	11	19
D	-7	4	8	11	21
E	-9	1	5	10	18
F	-7	2	6	10	28
G	-1	7	10	15	26
H	-6	3	8	13	33



# Modelo Hierárquico Normal

- Os intervalos de credibilidade novamente se interseccionam e a ordem é mantida. A média geral também não difere muito do estudo anterior.
- No entanto, os valores de estimativas pontuais diferem bastante da análise individual anterior. A variabilidade entre as estimativas pontuais é bem menor. A observação da distribuição a posteriori de  $\tau$  permite inferir sobre essa variabilidade.
- Comparando com a análise conjunta (único  $\theta$ ), notamos que os intervalos individuais para cada  $\theta_j$  possuem uma amplitude maior do que o intervalo único na análise global.
- Outra diferença  $P(\theta_1 > 28) \approx 0.10$  o que difere de ambas análises anteriores.
- Para mais detalhes ver Gelman et al. (2014).

## 1. Modelo t-Student

Mantemos a suposição de normalidade no nível 1 e flexibilizamos a suposição no nível 2.

$$\theta_j \mid \mu, \tau \sim t_\nu(\mu, \tau^2)$$

Considerando a representação hierárquica da distribuição t-Student, como mistura de normais, temos

$$y_j \mid \theta_j \sim N(\theta_j, \sigma_j^2)$$

$$\theta_j \mid \mu, \tau^2, \lambda_j \sim N(\mu, \tau^2 / \lambda_j)$$

$$\lambda_j \mid \nu \sim \text{Gama}(\nu/2, \nu/2)$$

# Modelos Hierárquicos mais flexíveis

- O modelo  $t$ -Student acomoda melhor observações discrepantes.
- Os novos parâmetros,  $\lambda_j$ , introduzidos no modelo podem ser usados para análise de *outliers*. Valores altos de  $\lambda_j$  estão associados a valores discrepantes.
- O modelo normal resulta quando  $\nu \rightarrow \infty$ .
- Um novo problema surge, escolher a distribuição a priori para os graus de liberdades  $\nu$ .

## 2. Modelos assimétricos

O modelo skew-normal também pode ser estabelecido de forma hierárquica a partir da normal.

$$y_j \mid \theta_j \sim N(\theta_j, \sigma_j^2)$$

$$\theta_j \mid \mu, \tau^2, \lambda, w_j \sim N(\mu + \lambda w_j, \tau^2)$$

$$w_j \sim N(0, 1)I_{(0, \infty)}$$

- O novo parâmetro  $\lambda \in R$  é um parâmetro de forma.
- Se  $\lambda = 0$  o modelo é simétrico, voltamos ao modelo normal.
- Se  $\lambda > 0$  [ $\lambda < 0$ ] resulta numa distribuição assimétrica positiva [negativa] .

**Correção da pag. 62 do livro Congdon (2014) :**

Se  $\frac{1}{\tau^2} \sim \text{Gama}(\epsilon, \epsilon)$  então, a distribuição a priori de  $\theta_j$  condicional a  $\mu$  tem distribuição  $t - \text{Student}$  com  $\nu = 2\epsilon$  graus de liberdades.

*Exercício !!*